Dicionário de Dados e Diagrama do Fluxo de Dados Projeto PTB-XL (Iniciação Científica)

Classificação Binária de Eletrocardiogramas: NORM vs. MI
Setembro de 2026

1. Dicionário de Dados (PTB-XL Short)

Este dicionário descreve os principais atributos e variáveis utilizados na extração, pré-processamento e pipeline de modelagem para a tarefa de classificação binária entre ECGs normais (NORM) e enfarto do miocárdio (MI).

Nome da Variável	Tipo de Dado	Descrição / Papel na Pipeline
ecg_id	Inteiro	Identificador único de cada exame de ECG no dataset PTB-XL.
patient_id	Inteiro (ID)	Identificador único do paciente. Chave essencial utilizada na estratificação (70/15/15) para evitar vazamento de dados (data leakage) entre conjuntos de treino, validação e teste.
age	Inteiro	Idade do paciente na data de realização do exame.
sex	Categórico	Gênero biológico do paciente (0: Masculino, 1: Feminino).
scp_codes	Dicionário / JSON	Códigos de diagnóstico estruturados no padrão SCP-ECG com as respectivas probabilidades.
diagnostic_class	Categórico	Classe macro derivada dos scp_codes. No nosso escopo, filtrada para NORM (Normal) e MI (Enfarto do Miocárdio).
strat_fold	Inteiro (1-10)	Fold de validação cruzada pré-definido recomendado pelos autores do dataset PTB-XL para partição reprodutível.
sig_len	Inteiro	Comprimento do sinal (ex: 5000 amostras para gravações de 10 segundos a 500 Hz).

2. Diagrama do Fluxo de Dados (Data Flow)

Abaixo está detalhado o fluxo sequencial dos dados no projeto, garantindo reprodutibilidade e integridade metodológica:

- **Etapa 1: Aquisição dos Dados Brutos:** Download e extração do dataset PTB-XL (sinais de 12 derivações a 500 Hz em formato WFDB e tabela ptbxl_database.csv).
- **Etapa 2: Filtragem de Escopo (Metadados):** Processamento dos scp_codes para mapear diagnósticos e seleção estrita das amostras pertencentes às classes NORM e MI.
- **Etapa 3: Estratificação por Paciente:** Divisão dos dados em Treino (70%), Validação (15%) e Teste (15%) agrupada por patient_id para impedir contaminação entre conjuntos.
- **Etapa 4: Carregamento do Sinal e Normalização:** Leitura das séries temporais via biblioteca wfdb e aplicação de normalização Z-score (média zero e variância unitária) por derivação.
- **Etapa 5: Formatação do Dataset Final:** Empacotamento das matrizes de sinal normalizado e respectivos rótulos prontos para alimentarem os modelos de aprendizado de máquina.